

Yapay Zekâ Destekli Görüntü Analizi ve Nesne Tabanlı Bilgi Getirme Sistemi

1. Projenin Amacı

Bu projede kullanıcı tarafından verilen bir görüntü içerisindeki ön plandaki nesnenin otomatik olarak tespit edilmesi, nesneye ait anlamlı anahtar kelimelerin oluşturulması ve bu bilgiler kullanılarak internet üzerinden ilgili içeriklerin kullanıcıya sunulması amaçlanmıştır.

Proje kapsamında yalnızca hazır bir görüntü sınıflandırma modeli kullanmak yerine, model eğitimi de gerçekleştirilmiştir. Bu amaçla OpenCLIP modeli doğrudan yeniden eğitilmemiş, önceden eğitilmiş ağırlıkları korunarak **özellik çıkarıcı (feature extractor)** olarak kullanılmıştır. CLIP tarafından üretilen yüksek seviyeli görüntü öznitelikleri üzerine ise **sıfırdan başlatılan çok katmanlı algılayıcı (MLPHead)** tasarlanmış ve Adam optimizasyon algoritması kullanılarak **60 epoch** boyunca eğitilmiştir. Literatürde bu yaklaşım, önceden eğitilmiş bir modelin yalnızca öznitelik çıkarımı amacıyla kullanılıp üzerine yeni bir sınıflandırıcının eğitilmesi nedeniyle **linear probing** veya kullanılan mimariye bağlı olarak **shallow probing** olarak adlandırılmaktadır.

Bu yaklaşım sayesinde, hazır bir modeli yalnızca kullanmak yerine proje kapsamında yeni bir sınıflandırıcı eğitilmiş ve veri kümesine özgü karar sınırlarının öğrenilmesi sağlanmıştır.

Böylece hem proje isterlerinde belirtilen model eğitimi kriteri karşılanmış hem de sınıflandırma performansının artırılması hedeflenmiştir.

Bunun yanında sistem, nesnenin tespit edilmesiyle sınırlı kalmayıp elde edilen nesne bilgisini kullanarak anahtar kelime üretmekte, web üzerinde ilgili içerikleri aramakta ve elde edilen bilgileri kullanıcıya özetleyerek sohbet benzeri bir kullanım deneyimi sunmaktadır.

2. Kullanılan Teknolojiler

Projede Python dili tercih edilmiştir. Bunun temel nedeni yapay zekâ ve görüntü işleme alanında geniş kütüphane desteğine sahip olmasıdır.

Projede kullanılan temel teknolojiler şunlardır:

- Python
- PyTorch
- OpenCLIP
- OpenCV
- Pillow (PIL)
- NumPy

- BeautifulSoup
- Requests
- DuckDuckGo Search API
- NLTK (WordNet)
- Scikit-Learn
- JSON

Bu kütüphaneler görüntü işleme, özellik çıkarımı, web araması, metin işleme ve sonuçların kaydedilmesi amacıyla birlikte kullanılmıştır.

3. Projenin Genel Çalışma Yapısı

Program çalıştırıldıktan sonra kullanıcıdan bir görüntü adresi alınmaktadır. Bu adres hem yerel dosya yolu hem de internet bağlantısı olabilmektedir.

Daha sonra sistem aşağıdaki işlemleri sırasıyla gerçekleştirmektedir:

1. Görüntü yüklenir.
2. Görüntü ön işleme adımlarından geçirilir.
3. Ön plandaki nesne belirlenir.
4. Nesne CLIP modeli kullanılarak sınıflandırılır.
5. Güven değeri yeterli değilse eğitilmiş MLP modeli devreye girer.
6. Nesneye ait anahtar kelimeler oluşturulur.
7. Anahtar kelimeler kullanılarak web üzerinde arama yapılır.
8. Elde edilen metinler temizlenir.
9. Metinler özetlenir.
10. Sonuçlar kullanıcıya gösterilir ve JSON dosyasına kaydedilir.

Bu yapı sayesinde sistem yalnızca nesneyi tanımakla kalmayıp kullanıcıya nesne hakkında anlamlı bilgiler de sunabilmektedir.

4. Kullanılan Yapay Zekâ Yaklaşımı

Projede temel görüntü temsil modeli olarak OpenCLIP kullanılmıştır.

CLIP modeli görüntü ile metni aynı özellik uzayına dönüştürdüğü için, nesnenin hangi sınıfa ait olduğu benzerlik hesaplanarak belirlenmektedir.

Model seçiminde OpenCLIP tercih edilmesinin temel nedeni, hazır eğitilmiş güçlü bir model olması ve sıfırdan model eğitmeye gerek bırakmamasıdır.

Bunun yanında yalnızca CLIP skorlarına bağlı kalınmamıştır.

CLIP'in güven değerinin düşük olduğu durumlarda ikinci aşama olarak tarafımdan eğitilmiş çok katmanlı algılayıcı (MLP) modeli kullanılmaktadır.

Bu yapı sayesinde özellikle birbirine benzeyen nesnelerde daha kararlı sonuçlar elde edilmektedir.

5. Prompt Ensembling Yaklaşımı

Tek bir metin ifadesi kullanıldığında CLIP modelinin başarısının düştüğü gözlemlendi.

Bu nedenle her nesne için farklı açıklamalardan oluşan birden fazla prompt hazırlanmıştır.

Örneğin yalnızca

a backpack

yerine

- a backpack
- a school backpack
- a travel backpack
- a photo of backpack

gibi farklı ifadeler kullanılmıştır.

Daha sonra bu ifadelerin embedding değerlerinin ortalaması alınarak tek bir temsil oluşturulmuştur.

Bu yöntem sayesinde modelin farklı görüntülerde daha tutarlı sonuç verdiği görülmüştür.

6. Ön İşleme Aşamaları

Modelin doğru çalışabilmesi için görüntüler üzerinde bazı ön işlemler uygulanmıştır.

Öncelikle görüntü RGB formatına dönüştürülmektedir.

Çünkü CLIP modeli RGB görüntüler üzerinde çalışmaktadır.

RGBA veya gri tonlamalı görüntüler doğrudan modele verirse başarımlar düşmektedir.

Daha sonra görüntü yeniden boyutlandırılarak modele uygun hale getirilmektedir.

Görüntü içerisinde arka planın etkisini azaltabilmek amacıyla mümkün olduğunca ön plandaki nesnenin kullanılmasına dikkat edilmiştir.

7. Anahtar Kelime Üretimi

Nesne belirlendikten sonra kullanıcıya yalnızca nesne ismini vermek yerine nesneyi tanımlayan ek anahtar kelimeler de oluşturulmaktadır.

Bu işlem sırasında WordNet sözlüğünden yararlanılmıştır.

WordNet içerisindeki çok genel kavramlar filtrelenmiş, mümkün olduğunca fiziksel nesneyi temsil eden anlamlar seçilmiştir.

Bu sayede elde edilen anahtar kelimeler web aramalarında daha başarılı sonuçlar üretmektedir.

8. Web Araması

Nesne ve oluşturulan anahtar kelimeler birlikte kullanılarak DuckDuckGo üzerinden web araması gerçekleştirilmektedir.

Arama sırasında alışveriş siteleri, reklam sayfaları ve sosyal medya içerikleri mümkün olduğunca filtrelenmiştir.

Amaç kullanıcıya doğrudan bilgi sağlayan içeriklere ulaşmaktır.

Birden fazla kaynaktan alınan metinler daha sonra tek bir metin haline getirilmektedir.

9. Metin Özetleme

Web üzerinden elde edilen içerikler oldukça uzun olabildiği için kullanıcıya doğrudan gösterilmemektedir.

Bunun yerine TF-IDF tabanlı bir önem puanı hesaplanmaktadır.

En yüksek puana sahip cümleler seçilerek kısa ve anlaşılır bir özet oluşturulmaktadır.

Bu yöntem sayesinde gereksiz tekrarlar azaltılmış ve okunabilirlik artırılmıştır.

10. Sonuçların Kaydedilmesi

Her işlem sonunda aşağıdaki bilgiler JSON formatında saklanmaktadır.

- Kullanıcının verdiği görüntü
- Tespit edilen nesne
- Anahtar kelimeler
- Güven değeri
- Web arama sonuçları
- Oluşturulan özet

Bu yapı sayesinde uygulama daha sonra analiz edilebilir hale gelmektedir.

11. Karşılaşılan Problemler

Proje geliştirilirken karşılaşılan en önemli problemler şunlardır:

- Bazı görüntülerin RGBA formatında olması
- Benzer nesnelerin birbirine karıştırılması
- Web sonuçlarının gereğinden uzun olması
- Bazı arama sonuçlarının reklam içerikli olması
- Çok genel anahtar kelimelerin anlamsız sonuçlar üretmesi

Bu problemlerin çözümü için görüntü ön işleme, prompt ensembling, MLP destekli sınıflandırma, WordNet filtreleme ve TF-IDF özetleme yöntemleri uygulanmıştır.

12. Sonuç

Bu projede kullanıcı tarafından verilen görüntü analiz edilerek ön plandaki nesne tespit edilmiş, nesneye ait anahtar kelimeler otomatik olarak oluşturulmuş ve bu bilgiler kullanarak internet üzerinden anlamlı içerikler elde edilmiştir.

Projeyi geliştirirken yalnızca hazır bir modeli kullanmak yerine, sınıflandırma doğruluğunu artırmak amacıyla ek yöntemler de uygulanmıştır. Özellikle CLIP modeli ile eğitilmiş MLP modelinin birlikte kullanılması, prompt ensembling yaklaşımı, WordNet tabanlı anahtar kelime üretimi ve TF-IDF ile metin özetleme sistemin daha başarılı çalışmasını sağlamıştır.

Genel olarak ortaya çıkan uygulama, verilen proje isterlerini karşılayan, modüler yapıda geliştirilen ve farklı görüntüler üzerinde çalışabilecek bir yapay zekâ destekli görüntü analiz sistemi olmuştur.